

Care& AI STT 시스템 설계 문서

음성 케어일지 전사(Speech-to-Text) — 엔진·파이프라인·API·운영

작성일: 2026-06-27 · 대상: careand.aiclaude.kr AI 서비스(FastAPI) + 백엔드(Laravel) · 엔진: faster-whisper (CPU int8)

1. 개요

Care& 는 요양보호사가 케어 세션 중 남긴 음성 기록을 텍스트로 전사(STT)하고, 이를 LLM/휴리스틱으로 요약하여 보호자·의료진용 케어일지를 생성한다. STT는 AI 서비스(FastAPI) 안에서 faster-whisper (CPU, int8 양자화)로 실행되어 있으며, 음성 업로드부터 일지 저장까지 비동기 큐로 처리한다.

핵심 설계 원칙: 인식 실패 시 가짜 텍스트를 절대 반환하지 않는다. 모델 부재·엔진 오류는 5xx로 응답하고 호출측이 실패로 처리하여, 잘못 인식된 일지가 보호자에게 노출되는 것을 막는다.

2. 처리 파이프라인

음성 업로드 → 큐 적재 → STT 전사 → LLM 요약 → 케어일지 저장 → (보호자 알림)

요양보호사가 세션에 음성을 업로드하면 VoiceLog 가 생성되고 ProcessVoiceLogJob 이 큐(Redis)에 적재된다. 워커가 STT→요약을 순차 수행하며 각 단계마다 VoiceLog 상태를 갱신한다. CPU 전사가 수 초 블로킹되므로 동기 처리하지 않고 큐로 이관했다.

단계	주체/엔드포인트	내용
1. 업로드	POST /care-sessions/{id}/voice-log	음성 저장 → VoiceLog 생성 → ProcessVoiceLogJob dispatch
2. 전사(STT)	AI: POST /ai/voice/transcribe	faster-whisper 전사 → stt_text·confidence (status=transcribed)
3. 요약	AI: POST /ai/voice/summarize	어르신 컨텍스트로 보호자/의료 요약 생성(LLM, 키 없으면 휴리스틱 폴백)
4. 저장	백엔드(AiLogSummary)	요약·분류 저장(status=summarized). 실패 시 status=failed·error_message

3. STT 엔진 사양

항목	값	비고
엔진	faster-whisper (CTranslate2)	OpenAI Whisper의 CT2 최적화 구현
디바이스 / 양자화	CPU / int8	GPU 없음. 메모리·속도 절충
모델	small-ct2 (현재) / base-ct2	WHISPER_MODEL 로 교체. small 464MB, base 142MB
스레드	cpu_threads = 2 (WHISPER_THREADS)	2코어 박스
로딩	lazy 로드(첫 호출 시) 후 상주	프로세스 메모리에 유지
동시성	추론 락으로 직렬화(_whisper_infer_lock)	2코어에서 동시 추론 방지
VAD	vad_filter = True	무음 구간 제거로 정확도·속도 개선
언어	기본 ko (요청 language)	info.language 로 감지 결과 반환

박스 가용 RAM이 빠듯하여(~1.7G) 기본 모델은 base. 정확도 향상을 위해 운영은 small 로
상향함(WHISPER_MODEL=/root/careand-ai-service/models/small-ct2). 그 이상(medium 등)은 RAM 주의.

4. STT API 명세

POST /ai/voice/transcribe · 인증: Bearer 토큰(AI_SERVICE_TOKEN)

요청

필드	타입	설명
audio_url	string	음성 파일 URL(http/https) 또는 서버 로컬 경로
language	string	전사 언어. 기본 ko

응답

필드	설명
stt_text	전사 텍스트(세그먼트 결합)
confidence	신뢰도 0~1 (avg_logprob 기반)
duration_sec	오디오 길이(초)
language	감지된 언어
model	사용 모델 라벨 (예: faster-whisper-small-ct2-int8)

5. 오디오 입력 처리

audio_url 이 http/https면 다운로드(최대 50MB, 30초 타임아웃) 후 임시파일로 전사하고 종료 시 삭제한다. 로컬
경로면 그대로 사용한다.

상황	HTTP	처리
정상	200	전사 결과 반환
50MB 초과	413	파일 과대(>50MB) 거부
빈 파일	422	empty audio file
URL 접근 불가	422	audio_url not reachable
모델 미준비	503	fetch_model.sh 로 모델 준비 필요
엔진 오류	502	STT engine error (가짜 텍스트 미반환)

6. 신뢰도(confidence) 산출

$\text{confidence} = \text{clamp}(\exp(\text{평균 avg_logprob}), 0, 1)$, 세그먼트 없으면 0.0

각 세그먼트의 평균 로그확률을 지수화하여 0~1로 환산한다. 값이 낮으면 잡음·발화 불명확 가능성이 높아 후속
요약·검수 시 참고 지표로 쓰인다.

7. 실패 처리 정책 (가짜 텍스트 금지)

- 모델 파일이 없으면 503 — 절대 임의/가짜 텍스트를 만들지 않는다(런타임 네트워크 다운로드도 안 함).
- 전사 엔진 예외는 502로 응답하고 임시파일을 정리한다.
- 백엔드 Job은 예외 시 VoiceLog.status=failed, error_message 기록 → 잘못된 일지가 보호자에게 노출되지 않는다(요약 단계로 진행하지 않음).

8. 모델 운영

- 모델 준비는 fetch_model.sh 전담(egress 플랩 대응 curl 재시도 다운로드). 서비스는 local_files_only=True 로 요청 시점에 절대 다운로드하지 않는다(행 방지).
- 모델은 models/ 하위에 디렉토리로 보관(base-ct2 142MB, small-ct2 464MB). WHISPER_MODEL 환경변수로 경로/이름 교체 후 서비스 재시작.
- 현재 운영 모델: small-ct2 (정확도 우선). 메모리 압박 시 base 로 하향 가능.

9. 백엔드 연동 및 상태 흐름

VoiceLog 상태: transcribing → transcribed → summarized (실패 시 failed). 호출 타임아웃은 전사 60초, 요약 30초이며 Job은 최대 3회 재시도(timeout 120초).

상태	의미
transcribing	STT 전사 진행 중
transcribed	전사 완료(stt_text·confidence 저장)
summarized	요약 생성·저장 완료(AiLogSummary)
failed	전사/요약 실패(error_message 기록)

10. 한계 및 향후 과제

- CPU·int8·small 모델 기준의 정확도/속도 한계. GPU·대형 모델은 현재 박스 RAM(~1.7G) 제약으로 미적용.
- 화자 분리(diarization)·실시간 스트리밍 미지원(파일 단위 일괄 전사).
- 요약 단계 LLM은 ANTHROPIC_API_KEY 미설정 시 휴리스틱 폴백으로 동작(전사 자체와는 무관).
- 도메인 특화 용어(약물명·질환명) 인식 향상을 위한 사후 교정 사전은 향후 과제.