



Care& AI 시스템 설계 문서

통합본 — 표지 · 목차 · 요약

플랫폼 시스템 개요 + 돌봄 플랫폼 AI 서비스(FastAPI) 5개 모듈 설계 모음

careand.aiclaude.kr · 2026-06-27 · v1.0

문서 소개

본 문서는 Care& 돌봄 플랫폼 AI 서비스(FastAPI, 단일 마이크로서비스)에 포함된 5개 AI 모듈의 개별 설계 문서를 묶는 통합 표지·목차이다. 각 시스템의 상세 내용은 동명의 개별 문서(.docx/.pdf)를 참조한다. 모든 모듈은 운영 환경 제약(CPU·메모리·외부망 제한)을 고려해 경량·규칙/휴리스틱 중심으로 구현되었으며, 실패 시 가짜 데이터를 만들지 않고 안전 폴백하는 원칙을 공유한다. 더불어 플랫폼 전체 시스템 구조(서버·컴포넌트·데이터·운영)를 '시스템 개요'로 요약한다.

시스템 개요 (플랫폼 구조)

Care& 통합돌봄 플랫폼은 서버 103.55.191.157의 Apache 가상호스트(careand.aiclaude.kr)에서 구동된다. 백엔드(Laravel)·웹 3종(Next.js)·AI 서비스(FastAPI)·큐 워커가 모두 systemd로 상시 가동되며, 데이터는 MySQL(careand_platform, 약 66개 테이블)과 Redis(캐시·큐·세션)에 저장된다.

컴포넌트	스택 · 포트	경로 / 비고
백엔드 API	Laravel 11 · PHP-FPM :9000	/api/v1 · DB MySQL careand_platform · JWT 인증
관리자 웹	Next.js :3105	/admin · 운영 12화면(실 API 연동)
회원 웹	Next.js :3106	/app · 보호자·인력(Flutter 앱 대체 웹)
공개 웹	Next.js :3107	/www · 비로그인 마케팅·탐색(공개 API)
AI 서비스	FastAPI :8001	/ai/* · 매칭·STT·이상징후·수요예측·챗봇
큐·캐시	careand-queue · Redis :6379	비동기 Job(매칭·음성일지) · 캐시 · 세션

배포는 컴포넌트별 careand-deploy 스크립트(롤백 빌드 보존)로 수행하고, 운영 크론(매일 백업 03:30 · 오프사이트 복제 04:10 · 5분 헬스 모니터)이 동작한다. 외부연동 6종(OTP/PG/FCM/NHIS/홈택스/복지부)은 스텝 모드이며 APP_ENV=production 하드닝이 적용되어 있다. 전체 시스템 상세는 통합본(병합) PDF의 'CAREAND-SYSTEM' 섹션을 참조한다.

1. AI 서비스 전체 구성

모듈	방식 / 모델	엔드포인트	상태
매칭	rule-v3 (규칙 + 이력 신호)	POST /ai/match/recommend	운영
STT(음성전사)	faster-whisper small-ct2 (CPU int8)	POST /ai/voice/transcribe	운영
이상징후	rule-v1 (고정 임계 규칙)	POST /ai/anomaly/score	운영
수요예측	seasonal-naive-v1 (요일 계절성)	POST /ai/forecast/demand	운영
챗봇	Gemini LLM + 폴백	/ai/chatbot/answer · /chatbot/postpartum	운영(Gemini)

공통 인증: Bearer 토큰(AI_SERVICE_TOKEN). 헬스: GET /health. 배포: careand-deploy ai.

2. 문서 목차

No	시스템	핵심 내용	파일 (docx / pdf)
1	AI 매칭	후보 풀 하드필터·rule-v3 점수화·성별 매칭(하드/소프트/무관)·카테고리 기준	CareAnd-AI매칭-설계서
2	AI STT	faster-whisper 전사·파이프라인·API·실패정책·모델운영	CareAnd-AI-STT-설계서

No	시스템	핵심 내용	파일 (docx / pdf)
3	AI 이상징후	영양·우울·섬망·낙상 규칙·점수·심각도·권고	CareAnd-AI-이상징후-설계서
4	AI 수요예측	요일 계절성·56일 이력·가용인력·입출력	CareAnd-AI-수요예측-설계서
5	AI 챗봇	일반·산후조리 챗봇·LLM 연동·폴백·KB·안전정책	CareAnd-AI-챗봇-설계서

3. 시스템별 요약

1) AI 매칭 (rule-v3)

백엔드가 자격·도메인·스킬·성별·기피로 후보 풀을 하드 필터링하고, AI가 특기·거리·평점(베이지안)·경험에 연속성(재돌봄)을 가산해 점수화한다. 성별은 카테고리별로 하드(방문목록)/소프트
권장(병원간병·방문요양·야간·단기)/무관(동행·가사)으로 차등 적용한다.

2) AI STT (faster-whisper)

케어 세션 음성을 CPU(int8) faster-whisper로 전사한다(현재 small-ct2). 업로드→큐→STT→요약 파이프라인이며, 인식 실패 시 가짜 텍스트 대신 5xx로 응답해 오인식 일지 노출을 방지한다.

3) AI 이상징후 (rule-v1)

식사·수면·정서·활력 지표로 영양·우울·섬망·낙상 4개 위험을 0~100 점수화하고 최고 위험을 심각도와 권고와 함께 알린다. 설명 가능성이 높은 고정 임계 규칙 기반이다.

4) AI 수요예측 (seasonal-naive-v1)

최근 56일 매칭요청 이력의 요일별 평균으로 향후 최대 30일 수요를 예측하고, 활성 인력 수를 함께 제공해 수급을 비교한다.

5) AI 챗봇 (LLM + 폴백)

장기요양 상담 챗봇과 산후조리 챗봇을 Gemini API로 제공하되, 키 미설정·실패 시 지식베이스 안내문/규칙 기반 답변으로 폴백한다. 의료 판단·위험 신호는 의료진 상담을 최우선 권고한다.

4. LLM(Gemini) 적용

LLM 기능은 프로바이더 선택형(LLM_PROVIDER)으로 구현되며 현재 Google Gemini(gemini-2.5-flash)를 사용한다(Anthropic 크레딧 소진 우회, Anthropic 경로도 코드상 유지). 적용은 3가지 패턴으로 나뉜다 — 순수 생성 하이브리드(결정적 코어 + Gemini 설명) 프로바이더 옵션(STT). 핵심 원칙은 '판정·순위·예측·수치는 결정적 코어가, 표현·설명·상담·생성·전사는 Gemini가' 담당하는 것이다.

4.1 적용 패턴

패턴	의미	적용 모듈
A. 순수 생성	출력 자체가 LLM 결과	챗봇·산후챗봇·일지요약·일지생성
B. 하이브리드	결정적 코어가 판정/순위/예측, Gemini는 설명만 덧붙임	매칭추천·산후매칭·이상징후·수요예측
C. 프로바이더 옵션	엔진 자체를 교체 가능	STT (whisper 기본 / gemini)

4.2 모듈별 적용

모듈	코어(결정적)	Gemini 적용	LLM 실패 시
일반·산후 챗봇	—	답변 생성(컨텍스트 반영)	규칙/KB 폴백
일지요약	—	보호자·의료진 요약(JSON)	heuristic 폴백
일지생성	—	보호자·의료진 일지	템플릿 폴백

모듈	코어(결정적)	Gemini 적용	LLM 실패 시
매칭추천	rule-v3 / L2R 순위	1순위 추천 사유 설명	설명만 생략
산후매칭	rule-v1 순위(DB직결)	1순위 추천 사유 설명	설명만 생략
이상징후	rule-v1 위험 점수·심각도	보호자용 설명	설명만 생략
수요예측	seasonal-naive 통계	운영자 인사이트	인사이트만 생략
STT	faster-whisper(로컬, 기본)	멀티모달 전사(옵션)	—(엔진 택1)

4.3 동시 적용 방식 · 공통 메커니즘

- 하이브리드는 한 응답에 코어 필드와 Gemini 필드가 공존한다. 예) 이상징후 = risk_type/severity/risk_score-model=rule-v1(규칙 판정) + guardian_explanation/explanation_model=gemini-2.5-flash(설명). 규칙이 먼저 판정하고, 그 결과를 입력으로 Gemini가 설명 필드만 추가한다.
- 프로바이더 스위치: LLM_PROVIDER(anthropic|gemini)로 llm_complete()가 분기. 현재 gemini-2.5-flash.
- thinking off(thinkingBudget=0): Gemini 2.5의 thinking이 출력 토큰을 잠식하는 문제를 방지.
- 견고성: 일시오류(429/500/503) 백오프 재시도, 마크다운 코드펜스 자동 제거.
- graceful degradation: 순수 생성은 규칙/템플릿 폴백, 하이브리드는 설명만 생략 — 코어·서비스는 절대 멈추지 않는다.
- 환각 차단: 하이브리드 프롬프트가 '규칙이 준 범위 안에서만, 새 수치·위험을 지어내지 말 것'을 명시.

4.4 설계 판단

- 위험 판정·순위·예측 등 재현 가능해야 하는 부분은 규칙/통계로 유지(환각이 치명적).
- STT는 케어 음성이 어르신 건강 PII므로 로컬 whisper를 기본 유지(Gemini STT는 녹음을 Google로 전송, 인라인 ~19MB 한도).
- Gemini는 사람이 읽는 부분(설명·상담·요약·생성·전사)에만 적용해 안전과 UX를 동시에 확보.

5. 공통 운영 정보

- 인증: 모든 엔드포인트 Bearer 토큰(AI_SERVICE_TOKEN, 백엔드 .env와 동일값).
- 비동기 처리: 매칭·음성일지는 백엔드 큐(careand-queue)로 처리, 즉시 응답 후 폴링.
- 폴백 철학: 모델 부재·호출 실패 시 가짜 결과를 만들지 않고 5xx 또는 안전 폴백으로 대응.
- 환경 제약: CPU·메모리·외부망 제한으로 대형/학습형 모델 대신 경량·규칙/휴리스틱 채택.
- 배포·상태: 컴포넌트별 careand-deploy ai 로 스냅샷·재시작, GET /health 로 모듈 상태 확인.

파일 위치: /root/ — 본 통합본과 5개 개별 문서(각 .docx/.pdf) 동일 디자인. 통합본: CareAnd-AI-설계문서-통합본.