



Care& AI 시스템 설계 문서

통합본 — 표지 · 목차 · 요약

플랫폼 시스템 개요 + 서비스 도메인 통합(멀티도메인) + 돌봄 플랫폼 AI 서비스(FastAPI) 5개 모듈 설계 모음

caren.aiclaude.kr · 2026-06-27 · v1.0

문서 소개

본 문서는 Care& 돌봄 플랫폼 AI 서비스(FastAPI, 단일 마이크로서비스)에 포함된 5개 AI 모듈의 개별 설계 문서를 묶는 통합 표지·목차이다. 각 시스템의 상세 내용은 동명의 개별 문서(.docx/.pdf)를 참조한다. 모든 모듈은 운영 환경 제약(CPU·메모리·외부망 제한)을 고려해 경량·규칙/휴리스틱 중심으로 구현되었으며, 실패 시 가짜 데이터를 만들지 않고 안전 폴백하는 원칙을 공유한다. 더불어 플랫폼 전체 시스템 구조(서버·컴포넌트·데이터·운영)를 '시스템 개요'로 요약한다.

시스템 개요 (플랫폼 구조)

Care& 통합돌봄 플랫폼은 서버 103.55.191.157의 Apache 가상호스트(caren.aiclaude.kr)에서 구동된다. 백엔드(Laravel)·웹 3종(Next.js)·AI 서비스(FastAPI)·큐 워커가 모두 systemd로 상시 가동되며, 데이터는 MySQL(careand_platform, 약 66개 테이블)과 Redis(캐시·큐·세션)에 저장된다.

컴포넌트	스택 · 포트	경로 / 비고
백엔드 API	Laravel 11 · PHP-FPM :9000	/api/v1 · DB MySQL careand_platform · JWT 인증
관리자 웹	Next.js :3105	/admin · 운영 12화면(실 API 연동)
회원 웹	Next.js :3106	/app · 보호자·인력(Flutter 앱 대체 웹)
공개 웹	Next.js :3107	/www · 비로그인 마케팅·탐색(공개 API)
AI 서비스	FastAPI :8001	/ai/* · 매칭·STT·이상징후·수요예측·챗봇
큐·캐시	careand-queue · Redis :6379	비동기 Job(매칭·음성일지) · 캐시 · 세션

배포는 컴포넌트별 careand-deploy 스크립트(롤백 빌드 보존)로 수행하고, 운영 크론(매일 백업 03:30 · 오프사이트 복제 04:10 · 5분 헬스 모니터)이 동작한다. 외부연동 6종(OTP/PG/FCM/NHIS/홈택스/복지부)은 스텝 모드이며 APP_ENV=production 하드닝이 적용되어 있다. 전체 시스템 상세는 통합본(병합) PDF의 'CAREAND-SYSTEM' 섹션을 참조한다.

1. AI 서비스 전체 구성

모듈	방식 / 모델	엔드포인트	상태
매칭	rule-v3 (규칙 + 이력 신호)	POST /ai/match/recommend	운영
STT(음성전사)	faster-whisper small-ct2 (CPU int8)	POST /ai/voice/transcribe	운영
이상징후	rule-v1 (고정 임계 규칙)	POST /ai/anomaly/score	운영
수요예측	seasonal-naive-v1 (요일 계절성)	POST /ai/forecast/demand	운영
챗봇	Gemini LLM + 폴백	/ai/chatbot/answer · /chatbot/postpartum	운영(Gemini)

공통 인증: Bearer 토큰(AI_SERVICE_TOKEN). 헬스: GET /health. 배포: careand-deploy ai.

2. 문서 목차

No	시스템	핵심 내용	파일 (docx / pdf)
1	AI 매칭	후보 풀 하드필터·rule-v3 점수화·성별 매칭(하드/소프트/무관)·카테고리 기준	CareAnd-AI매칭-설계서
2	AI STT	faster-whisper 전사·파이프라인·API·실패정책·모델운영	CareAnd-AI-STT-설계서
3	AI 이상징후	영양·우울·섬망·낙상 규칙·점수·심각도·권고	CareAnd-AI-이상징후-설계서
4	AI 수요예측	요일 계절성·56일 이력·가용인력·입출력	CareAnd-AI-수요예측-설계서
5	AI 챗봇	일반·산후조리 챗봇·LLM 연동·폴백·KB·안전정책	CareAnd-AI-챗봇-설계서

3. 시스템별 요약

1) AI 매칭 (rule-v3)

백엔드가 자격·도메인·스킬·성별·기피로 후보 풀을 하드 필터링하고, AI가 특기·거리·평점(베이지안)·경험에 연속성(재돌봄)을 가산해 점수화한다. 성별은 카테고리별로 하드(방문목욕)/소프트 권장(병원간병·방문요양·야간·단기)/무관(동행·가사)으로 차등 적용한다.

매칭 방식은 두 가지다 — 자동 매칭(위 rule-v3 추천)과 **보호자 수동 매칭**: 보호자가 케어자를 여러 명 직접 선택하면, 지목된 케어자 중 **가장 먼저 수락(신청)한 1명과 선착순으로 자동 매칭된다**(나머지 지목 건은 마감).

2) AI STT (faster-whisper)

케어 세션 음성을 CPU(int8) faster-whisper로 전사한다(현재 small-ct2). 업로드→큐→STT→요약 파이프라인이며, 인식 실패 시 가짜 텍스트 대신 5xx로 응답해 오인식 일지 노출을 방지한다.

3) AI 이상징후 (rule-v1)

식사·수면·정서·활력 지표로 영양·우울·섬망·낙상 4개 위험을 0~100 점수화하고 최고 위험을 심각도와 권고와 함께 알린다. 설명 가능성이 높은 고정 임계 규칙 기반이다.

4) AI 수요예측 (seasonal-naive-v1)

최근 56일 매칭요청 이력의 요일별 평균으로 향후 최대 30일 수요를 예측하고, 활성 인력 수를 함께 제공해 수급을 비교한다.

5) AI 챗봇 (LLM + 폴백)

장기요양 상담 챗봇과 산후조리 챗봇을 Gemini API로 제공하되, 키 미설정·실패 시 지식베이스 안내문/규칙 기반 답변으로 폴백한다. 의료 판단·위험 신호는 의료진 상담을 최우선 권고한다.

4. LLM(Gemini) 적용

LLM 기능은 프로바이더 선택형(LLM_PROVIDER)으로 구현되며 현재 Google Gemini(gemini-2.5-flash)를 사용한다(Anthropic 크레딧 소진 우회, Anthropic 경로도 코드상 유지). 적용은 3가지 패턴으로 나뉜다 — 순수 생성 하이브리드(결정적 코어 + Gemini 설명) 프로바이더 옵션(STT). 핵심 원칙은 '판정·순위·예측·수치는 결정적 코어가, 표현·설명·상담·생성·전사는 Gemini가' 담당하는 것이다.

4.1 적용 패턴

패턴	의미	적용 모듈
A. 순수 생성	출력 자체가 LLM 결과	챗봇·산후챗봇·일지요약·일지생성

패턴	의미	적용 모듈
B. 하이브리드	결정적 코어가 판정/순위/예측, Gemini는 설명만 덧붙임	매칭추천·산후매칭·이상징후·수요예측
C. 프로바이더 옵션	엔진 자체를 교체 가능	STT (whisper 기본 / gemini)

4.2 모듈별 적용

모듈	코어(결정적)	Gemini 적용	LLM 실패 시
일반·산후 챗봇	—	답변 생성(컨텍스트 반영)	규칙/KB 폴백
일지요약	—	보호자·의료진 요약(JSON)	heuristic 폴백
일지생성	—	보호자·의료진 일지	템플릿 폴백
매칭추천	rule-v3 / L2R 순위	1순위 추천 사유 설명	설명만 생략
산후매칭	rule-v1 순위(DB직결)	1순위 추천 사유 설명	설명만 생략
이상징후	rule-v1 위험 점수·심각도	보호자용 설명	설명만 생략
수요예측	seasonal-naive 통계	운영자 인사이트	인사이트만 생략
STT	faster-whisper(로컬, 기본)	멀티모달 전사(옵션)	—(엔진 택1)

4.3 동시 적용 방식 · 공통 메커니즘

- 하이브리드는 한 응답에 코어 필드와 Gemini 필드가 공존한다. 예) 이상징후 = risk_type/severity/risk_score·model=rule-v1(규칙 판정) + guardian_explanation/explanation_model=gemini-2.5-flash(설명). 규칙이 먼저 판정하고, 그 결과를 입력으로 Gemini가 설명 필드만 추가한다.
- 프로바이더 스위치: LLM_PROVIDER(anthropic|gemini)로 llm_complete()가 분기. 현재 gemini-2.5-flash.
- thinking off(thinkingBudget=0): Gemini 2.5의 thinking이 출력 토큰을 잠식하는 문제를 방지.
- 견고성: 일시오류(429/500/503) 백오프 재시도, 마크다운 코드펜스 자동 제거.
- graceful degradation: 순수 생성은 규칙/템플릿 폴백, 하이브리드는 설명만 생략 — 코어·서비스는 절대 멈추지 않는다.
- 환각 차단: 하이브리드 프롬프트가 '규칙이 준 범위 안에서만, 새 수치·위험을 지어내지 말 것'을 명시.

4.4 설계 판단

- 위험 판정·순위·예측 등 재현 가능해야 하는 부분은 규칙/통계로 유지(환각이 치명적).
- STT는 케어 음성이 어르신 건강 PII이므로 로컬 whisper를 기본 유지(Gemini STT는 녹음을 Google로 전송, 인라인 ~19MB 한도).
- Gemini는 사람이 읽는 부분(설명·상담·요약·생성·전사)에만 적용해 안전과 UX를 동시에 확보.

5. 공통 운영 정보

- 인증: 모든 엔드포인트 Bearer 토큰(AI_SERVICE_TOKEN, 백엔드 .env와 동일값).
- 비동기 처리: 매칭·음성일지는 백엔드 큐(careand-queue)로 처리, 즉시 응답 후 폴링.
- 폴백 철학: 모델 부재·호출 실패 시 가짜 결과를 만들지 않고 5xx 또는 안전 폴백으로 대응.
- 환경 제약: CPU·메모리·외부망 제한으로 대형/학습형 모델 대신 경량·규칙/휴리스틱 채택.
- 배포·상태: 컴포넌트별 careand-deploy ai 로 스냅샷·재시작, GET /health 로 모듈 상태 확인.

파일 위치: /root/ — 본 통합본과 5개 개별 문서(각 .docx/.pdf) 동일 디자인. 통합본: CareAnd-AI-설계문서-통합본.

6. 서비스 도메인 통합 (멀티도메인)

Care& 플랫폼은 6개 서비스 도메인(소비자 노출 5 + 기관 전용 간병 1)을 하나의 앱·단일 스키마로 통합한다.

match_requests.service_domain enum 한 컬럼이 도메인을 구분하고, 도메인

메타데이터(라벨·대상선택기·카테고리·자격정책)는 config/service_domains.php 레지스트리(SSOT)가 단일 정의해 백엔드·웹·관리자·AI가 공유한다. 매칭·가격·정산·일지는 도메인 무관 동일 파이프라인이며, AI 매칭(rule-v3)도 도메인 가중치를 이 레지스트리에서 읽는다. 신규 도메인 = 레지스트리 1항목 + 카테고리/요율 시드.

6.1 도메인 · 직군(카테고리) 단가

도메인	카테고리 — 기준 시급(원)
요양보호 (senior)	방문요양 18,000 · 야간케어 22,000 · 단기보호 20,000 · 방문목욕 25,000
생활지원서비스 (living_support)	가사청소 18,000 · 정리수납 22,000 · 가사수리 35,000 · 동행 14,000
병원간병 (nursing · 기관 전용)	병원간병 15,000
산모·산후관리 (postpartum)	산후관리 13,000 · 산후 야간케어 16,000
아이돌봄 (childcare)	등하원동행 12,000 · 놀이돌봄 13,000 · 영아돌봄 15,000
마음돌봄 (mental_care)	정서지원 15,000 · 심리상담동행 16,000

기준 시급(base_rate). 실제 시급 = base_rate × region_index × 시간대배수(야간 1.30 / 휴일 1.50 / 긴급 1.20) + acuity 가산(치매 1,500 · 와상 2,000 · 석션 3,000 등), 하한 10,030원(법정 최저시급 연동).

6.2 도메인 자격 · 외부 진위조회

도메인	자격번호	인정 자격(license_type) · 진위조회
요양보호	필수	요양보호사 / 자동(보건복지부)
병원간병	필수	요양보호사·간호조무사·간병사·간호사 / 자동(복지부·국시원·민간자격정보)
산모·산후관리	필수	산후관리사·간호사·간호조무사 / 자동(민간자격정보·국시원·복지부)
생활지원서비스	선택(무자격 허용)	제한 없음 / 관리자 승인
아이돌봄	선택(권장)	아이돌보마·보육교사·유치원정교사·베이비시터 / 수동
마음돌봄	필수	상담심리사·임상심리사·정신건강임상심리사·청소년상담사 등 / 수동(자동 API 부재)

자격 진위조회는 자격종류(license_type) 기반 라우팅(CredentialVerifier): 요양보호사·간호조무사 → 보건복지부, 간호사 → 한국보건의료인국가시험원(국시원), 산후관리사·간병사 → 민간자격정보서비스(직능원). 자동 도메인은 진위 성공 시 자격확정(license_verified), 실패 시 반려(사유에 기관명). 상담 계열은 자동 API 부재로 관리자 수동 검증. 산모·간병 등 자동조회 상태(발급기관·완료/실패)는 관리자 승인 화면 검증보조에 표시된다. 현재 외부망 제약으로 스텝 모의응답이며, 실 기관 URL/KEY 협약 후 동일 코드경로로 실연동된다.

6.3 가입 의도 기반 홈 개인화 (도메인 카드 최상단)

도메인 요청자로 가입하면 회원앱 홈(/app/home) 서비스 허브에서 해당 도메인 카드가 최상단 featured(큰 카드)로 승격된다. 가입 화면의 요청자 종류(kind)가 role=guardian + intent로 파생돼 guardians.intent에 영속되고, 홈은 우선순위 [최근 요청 도메인 → 가입 intent → 대상정보 보유 풀백 → 기본(요양보호)]로 featured를 결정한다. intent→도메인 매핑은 housekeeping→living_support, 그 외(postpartum/childcare/mental_care)는 동명 도메인이며 care/미지정은 개인화 없이 요양보호가 최상단이다.

가입 종류	intent	홈 최상단 카드
어르신 돌봄	care	요양보호 (기본)
아이돌봄	childcare	아이돌봄

가입 종류	intent	홈 최상단 카드
마음돌봄	mental_care	마음돌봄
산모·산후관리	postpartum	산모·산후관리
가사	housekeeping → living_support	생활지원서비스

핵심 의존성·수정: 홈은 저장된 user.guardian.intent를 읽으며, UserResource가 whenLoaded('guardian')이라 auth 응답이 guardian을 eager-load해야 intent가 실린다. login/me는 load가 있었으나 signup만 누락돼 가입 직후 홈에서 intent=null → 카드 미승격(재로그인해야 동작)이던 버그를, signup 응답에도 \$user->load([...]) 추가로 login/me와 통일해 해결(backend 9c80578, member-web 302145b). login 응답도 intent 포함 + localStorage (careand-member-auth) 지속 → 재로그인·앱 재실행(재수화) 후에도 카드 최상단 유지. 라이브 e2e 5종(어르신·아이돌봄·마음돌봄·산모·가사) 가입 직후·재로그인·앱 재실행 전부 PASS.

Care& 통합돌봄 플랫폼

시스템 구조 · 서버 디렉토리 · 기능 정리


서버 103.55.191.157 (Rocky Linux 8.10) · vhost caren.aiclaude.kr · 작성일 2026-06-11 · APP_ENV=production

1. 개요

사업계획서 「Care&」 기반 통합돌봄 플랫폼. 노인 방문요양 + 산후조리(Phase 2) + 요양보호사 교육/프랜차이즈를 포괄한다. 단일 서버에 백엔드·관리자웹·회원웹·AI서비스·큐워커·DB·Redis가 전부 systemd 상시 가동된다.

환경 제약: 아웃바운드 egress가 화이트리스트로 제한된다. Google·AWS·GitHub HTTPS는 통과하지만 SMTP 및 일반 외부는 차단된다.

2. 시스템 아키텍처



3. 서버 디렉토리 구조

경로	크기	내용
/var/www/careand-backend	128M	Laravel 11 백엔드 API (PHP-FPM, public이 vhost 루트)
/root/careand-admin-web	753M	관리자 웹 (Next.js, :3105, /admin)
/root/careand-member-web	901M	회원 웹 (보호자/인력, Next.js, :3106, /app)
/root/careand-ai-service	660M	AI 마이크로서비스 (FastAPI, :8001, faster-whisper 모델 포함)
/usr/local/bin/careand-*	—	운영 스크립트 4종 (deploy/backup/offsite/monitor)
/etc/cron.d/careand	—	운영 크론 (백업·모니터·오프사이트)
/root/careand-hardening-snap-20260611	—	롤백 스냅샷 (DB덤프·.env·모니터백업·신규비번)

4. 구성요소별 상세

백엔드 API — Laravel 11 (PHP-FPM :9000)

- 라우트 총 116개 / api 111개, JWT 인증(access_token)
- 주요 그룹: admin(28) · postpartum 산후(19) · seniors(11) · caregivers(8) · auth(7) · care-sessions(7) · matching(7) · anomaly-alerts(5) · chatbot(5) · notifications(4) · payments(4) · settlements(3)
- 비동기 Job 3종: GenerateCareLogJob(LLM 일지생성) · GenerateMatchCandidatesJob(AI 매칭후보) · ProcessVoiceLogJob(음성 STT, 이번 신설)
- 외부연동(스텝): OTP/SMS · PG결제 · FCM푸시 · NHIS건보 · 홈택스 · 복지부

관리자 웹 — Next.js (:3105 → /admin) : 12화면, 사업계획서 #17~#26 전부 실API 연동

회원 웹 — Next.js (:3106 → /app) : 보호자/인력 매칭요청·후보선택·수락거절·출퇴근·정산·알림 (Flutter 앱 대체 웹)

AI 서비스 — FastAPI (:8001)

AI 엔진	상태
matching (매칭 추천)	rule-v1 (규칙기반 점수화)
STT (음성→텍스트)	faster-whisper-base-ct2-int8 실모델 (lazy 로드)
forecast (수요예측)	seasonal-naive-v1 (DB 이력)
anomaly (이상징후)	rule-v1
LLM / RAG (챗봇·일자·요약)	fallback — ANTHROPIC_API_KEY 미설정(키 충전 필요)

엔드포인트: /ai/match/recommend · /ai/voice/transcribe · /ai/voice/summarize · /ai/forecast/demand · /ai/anomaly/score · /ai/chatbot/answer · /care-log/generate · /matching/postpartum · /chatbot/postpartum

큐 워커 / DB / Redis

· careand-queue: queue:work redis (Job 코드 변경 시 restart 필수) · MariaDB careand_platform 66 테이블 · Redis: 캐시·큐·세션 백엔드

5. 데이터 모델 (66 테이블, 도메인별)

도메인	주요 테이블
사용자/조직	users, admins, guardians, caregivers, seniors, organizations, branches
매칭	match_requests, match_candidates, matches
케어세션	care_sessions, attendance_logs, care_activities, care_photos, voice_logs
AI	ai_models, ai_inference_logs, ai_recommendations, ai_log_summaries, anomaly_alerts, health_timeseries, vital_records
챗봇	chatbot_sessions/messages, postpartum_chatbot_*
산후(Phase2)	postpartum_clients, newborns, newborn_daily_logs, newborn_anomaly_alerts, epds_assessments, ltc_vouchers, voucher_transactions
결제/정산	payments, payment_items, settlements, settlement_items
교육	courses, course_lessons/sessions, enrollments, instructors, mock_interviews, certifications, career_milestones, mentor_pairings
프랜차이즈	franchise_applications/contracts/settlements/data_policies
시스템	notifications, audit_logs, failed_jobs(신설), personal_access_tokens, migrations

6. 운영 인프라 (자동화)

스크립트	스케줄	기능
careand-deploy	수동	git+빌드 배포 (롤백 빌드 보존)
careand-backup	매일 03:30	DB/설정/git 로컬 백업
careand-offsite	매일 04:10	103.55.190.159로 오프사이트 복제
careand-monitor	5분마다	systemd 8유닛+API+웹2 헬스, 상태변화 시 로그 + 메일 알림(이번 추가)

7. 이번 세션 변경사항

A. 운영 전환 하드닝 (커밋 e63e373, APP_ENV=production)

- 외부연동 6서비스 스텝을 APP_ENV에서 분리(config services.external.stub) → 전환해도 로그인/결제/푸시 안 깨짐
- 음성 STT production 미동작 버그 → ProcessVoiceLogJob 큐 신설
- failed_jobs 테이블 생성(큐 실패 추적)
- APP_DEBUG=off, LOG_LEVEL=warning, SESSION_SECURE_COOKIE=true, APP_URL=https
- 데모 비번 31계정 강비번 교체(admin1234/test1234 폐기) → 스냅샷 폴더 보관
- 검증: 신규비번 200 / 구비번 401 / 인증API 200 / 웹앱 200

B. 모니터 메일 알림 (진행 중)

- egress 진단으로 SMTP 차단 / Google·AWS HTTPS 허용 확인
- 발송 경로를 Google Apps Script webhook으로 전환, careand-monitor에 webhook/smtp 분기 + test 명령 추가
- /etc/careand-alert.conf(0600) 구성 완료 — Apps Script /exec URL + TOKEN 입력만 남음

8. 현재 상태 / 미해결

항목	상태
코어 서비스 8종	전부 active
운영 전환 하드닝	완료·검증
모니터 메일 알림	진행 — Apps Script URL/TOKEN 대기
LLM 챗봇·일지생성	코드완료, Anthropic 키 크레딧 소진으로 fallback
careand-ml 실매칭	미적용(egress+무거운 의존성), 현재 rule-v1
카카오맵	디벨로퍼스 승인 대기
PG/FCM/NHIS/홈택스/복지부	스텝(실 자격증명·연동 미준비)



Care& AI 매칭 설계 문서

돌봄전문가 자동 매칭 — 카테고리별 매칭 기준 및 매칭 알고리즘 (rule-v3)

작성일: 2026-06-27 · 개정: 2026-06-28(L2R 추가) · 대상: caren.aiclaude.kr 매칭 엔진(백엔드 Laravel + AI 서비스 FastAPI) ·
버전: rule-v3 + L2R(데이터 임계 게이트)

1. 개요

Care& 플랫폼은 보호자(또는 기관)의 매칭 요청에 대해 적격 돌봄전문가를 자동으로 선별·점수화하여 상위 후보를 추천한다. 매칭은 두 단계로 구성된다. (1) 백엔드(Laravel)가 자격·도메인·안전 조건으로 후보 풀을 하드 필터링하고, (2) AI 서비스(FastAPI)가 다중 신호로 점수화·정렬하여 상위 K명을 반환한다. 무거운 학습형 모델 대신 규칙·휴리스틱 기반(rule-v3)으로 구현되어 있으며 DB 이력 신호(연속성·평점 표본)를 활용한다.

2. 전체 매칭 플로우

매칭 요청 생성 → 후보 풀 구성(백엔드 하드 필터) → AI 점수화·정렬 → 상위 후보 저장 → 보호자 선택

운영 환경에서는 비동기 큐(Redis, careand-queue)로 처리한다. 요청 생성 즉시 응답하고 GenerateMatchCandidatesJob 이 후보를 산출한다(보호자는 폴링으로 확인). 로컬/테스트는 동기 경로로 즉시 처리하며 두 경로의 필터·정책은 동일하다.

매칭은 두 가지 방식을 지원한다. (1) 자동 매칭 — AI가 후보를 점수화·정렬해 상위 후보를 추천하는 방식으로 아래 3~8장의 파이프라인을 따른다. (2) 보호자 수동 매칭 — 보호자가 케어자를 직접 여러 명 선택하고, 지목된 케어자 중 가장 먼저 수락(신청)한 1명과 매칭하는 선착순 방식(9장). 별도 지정이 없으면 자동 매칭이 기본이다.

2.1 요청 진입 개인화 — 홈 도메인 카드

회원앱 홈(/app/home) 서비스 허브는 매칭 요청 생성 이전 단계에서 사용자를 도메인으로 유도한다. 가입 시 선택한 요청자 종류(kind)가 role=guardian + intent로 파생돼 guardians.intent에 영속되며, 홈은 우선순위 [최근 요청 도메인 → 가입 intent → 대상정보 보유 → 기본(요양보호)]로 해당 도메인 카드를 최상단 featured로 승격한다(intent→도메인: housekeeping→living_support, 그 외 postpartum/childcare/mental_care는 동명). 즉 '가입 목적 도메인'이 매칭 요청 진입점으로 선노출된다. 이는 점수화(5장)와 무관한 진입 UX 개인화이며, 실제 매칭은 선택된 도메인의 요청이 생성된 뒤 아래 파이프라인(3~5장)을 따른다. 구현 주의: 홈은 저장된 user.guardian.intent를 읽으므로 auth 응답이 guardian을 eager-load해야 하며, signup 응답의 eager-load 누락 버그는 backend 9c80578로 login/me와 통일해 수정(member-web 302145b). 재로그인·앱 재실행 후에도 유지되며 라이브 e2e 5종(어르신·아이돌봄·마음돌봄·산모·가사) 전부 PASS.

단계	주체	내용
1. 요청	보호자/기관	대상자·카테고리·일정·요구사항으로 매칭 요청 생성(status=open)
2. 풀 구성	백엔드	자격·도메인·스킬·성별·기피 조건으로 적격 인력 하드 필터링
3. 점수화	AI 서비스	다중 신호로 0~1 점수 산출, 정렬, 상위 top_k 반환
4. 저장	백엔드	match_candidates 저장(rank·ai_score·ai_reasons), status 갱신
5. 선택	보호자	후보 중 1명 선택 → 인력 수락/거절 → 계약·세션 진행

3. 후보 풀 구성 — 하드 필터

AI 점수화 이전에 백엔드가 아래 조건을 모두 만족하는 인력만 풀에 포함한다. 점수와 무관하게 미충족 시 제외된다.

필터	조건	적용 범위
활성 상태	status = active	전체
자격 검증	license_verified_at 존재	전체
도메인 적격	service_domains 에 요청 도메인 포함(FIND_IN_SET)	전체
스킬 보유	specialties 에 요구 스킬 포함	가사(HK_*)만

필터	조건	적용 범위
동성 매칭	gender = 대상자 성별	방문목록(BATH)만
기피 제외	caregiver_block의 기피 대상 제외	전체

4. 공급 희박 풀백 정책

적격 인력 0으로 인한 침묵 만료를 막는 단계적 완화. 단, 안전 조건(동성 매칭)은 어떤 풀백에서도 완화하지 않는다.

풀백	발동 조건	동작	비고
스킬 완화	스킬 보유 풀 0	도메인 적격자 전체로 재조회	가사, 동성 필터 유지
임계 완화	임계 점수로 후보 0	min_score=0 으로 재점수화	좌표·신규 인력 구제
선호 성별 임계 우회	선호 성별 지정	선호 성별 인력은 임계와 무관하게 항상 포함	소수 성별 구제

5. 점수화 알고리즘 (rule-v3)

base = w_특기·특기점수 + w_거리·거리점수 + w_평점·평점점수(베이지안) + w_경험·경험점수

final = 0.85 · base + 0.15 · 연속성점수

신호	정의	비고
특기점수	대상자 질환과 인력 특기의 교집합 비율. 질환없음=0.5, 일치=비율, 불일치=0.3	0~1
거리점수	1 거리(km)/10 (Haversine). 좌표 미상=0.5	0~1
평점점수	베이지안 보정 평점/5. (5·3.5 + n·평균)/(5+n)	표본 적은 고평점 과대평가 차단
경험점수	min(완료세션수 / 100, 1.0)	0~1
연속성점수	동일 대상자 과거 수락 매칭 횟수. min(횟수/3, 1.0)	가산식 — 이력없으면 랭킹 보존

도메인	특기	거리	평점	경험	설명
시니어(senior)	0.40	0.30	0.20	0.10	질환·특기 정합 중시
간병(nursing)	0.40	0.30	0.20	0.10	환자 상태·특기 정합 중시

도메인	특기	거리	평점	경험	설명
생활지원(living_support)	0.40	0.30	0.20	0.10	청소·정리·수리·동행(←가사 리네임), 근접성도 고려
산모·산후(postpartum)	0.40	0.30	0.20	0.10	산모·신생아 케어 특기 정합
아이돌봄(childcare)	0.40	0.30	0.20	0.10	등하원·놀이·영아, 근접성 함께 고려
마음돌봄(mental_care)	0.40	0.30	0.20	0.10	상담·정서지원 특기 정합

페이지안 평점 예시: 1건@5.0 → 0.75 vs 200건@4.8 → 0.954. 표본 적은 단발 만점이 베테랑을 앞서지 못하게 한다.

6. 성별 매칭 정책

등급	동작	대상 카테고리
하드 강제	반대 성별을 풀에서 제외(풀백서도 유지). 동성 없으면 후보 0.	방문목욕
소프트 권장	선호 성별을 대상자 성별로 자동 프리셋(변경 가능). 동성 우선 정렬, 미일치 풀백 유지.	병원간병·방문요양·야간케어·단기보호·산후관리·산후 야간케어
무관	성별 선호 미적용. 순수 점수 정렬.	동행·생활지원(청소·수리·정리)·아이돌봄·마음돌봄

- 소프트는 점수 가산이 아니라 ‘정렬 파티션’ — 일치 성별을 상위, 미일치는 풀백으로 유지(빈 결과 방지). 선호 성별 인력은 임계(min_score) 우회로 항상 포함.
- 하드(방문목욕)는 신체 노출을 동반하므로 반대 성별을 완전 배제 — 동성 없으면 매칭하지 않음.
- 소프트 채택 이유: 인력 성별 불균형(예: 간병 남성만)에서 하드 강제 시 반대 성별 대상자가 영구 0건 만료되어 서비스 마비.

7. 카테고리별 매칭 기준 (종합)

카테고리	도메인	요구 스킬	성별 정책	대상자
방문요양 VISIT_CARE	시니어	—	소프트 권장	어르신
야간케어 NIGHT_CARE	시니어	—	소프트 권장	어르신
단기보호 SHORT_STAY	시니어	—	소프트 권장	어르신
방문목욕 BATH	시니어	—	하드 강제	어르신
병원간병 NURSING_HOSPITAL	간병	—	소프트 권장	환자

카테고리	도메인	요구 스킬	성별 정책	대상자
가사청소 HK_CLEANING	생활지원	hk_cleaning	무관	주소(장소)
가사수리 HK_REPAIR	생활지원	hk_repair	무관	주소(장소)
정리수납 HK_ORGANIZING	생활지원	hk_organizing	무관	주소(장소)
동행 LS_COMPANION	생활지원	—	무관	주소(장소)
산후관리 PP_CARE	산모·산후	—	소프트 권장	산모
산후 야간케어 PP_NIGHT	산모·산후	—	소프트 권장	산모
등하원동행 CC_PICKUP	아이돌봄	—	무관	아이
놀이돌봄 CC_PLAY	아이돌봄	—	무관	아이
영아돌봄 CC_INFANT	아이돌봄	—	무관	아이
정서지원 MC_SUPPORT	마음돌봄	—	무관	본인/가족
심리상담동행 MC_COMPANION	마음돌봄	—	무관	본인/가족

생활지원 도메인(청소·수리·정리·동행)은 대상이 사람이 아니라 주소(장소)이므로 동성 매칭이 성립하지 않는다(성별 무관). 아이돌봄·마음돌봄은 현재 성별 무관이며, 필요 시 보호자가 선호 성별을 지정한다.

8. 매칭 상태 흐름

상태	의미
open	요청 생성됨, 후보 산출 대기/진행
matched	후보 산출 완료(보호자 선택 대기)
matching	보호자가 후보 선택 → 인력 응답 대기
expired	적격 인력 0 → 후보 미산출(만료)

9. 보호자 수동 매칭 (직접 선택 · 선착순 수락)

자동 매칭(2~8장)은 AI가 적격 인력을 점수화·정렬해 추천한다. 이와 별개로, 보호자가 원하는 돌봄전문가를 직접 지목하는 **수동 매칭**을 제공한다. 보호자는 케어자 목록에서 마음에 드는 **여러 명을 선택**해 매칭 요청을 보내고, 지목된 케어자들이 요청을 확인해 수락(신청)하면 **가장 먼저 신청한 케어자 1명과 자동으로 매칭된다(선착순)**. 후보 선정의 주도권은 보호자에게 있고, 성사 결정은 케어자의 응답(신청) 순서로 정해진다.

9.1 처리 흐름

단계	주체	내용
1. 케어자 탐색	보호자	케어자 목록·프로필에서 조건에 맞는 인력 열람
2. 다중 선택	보호자	원하는 케어자 여러 명을 선택해 수동 매칭 요청 생성(status=open)
3. 통보	시스템	지목된 케어자 전원에게 요청 도착 알림 동시 발송
4. 수락(신청)	케어자	각 케어자가 요청을 확인해 수락 또는 거절(수락=신청)

단계	주체	내용
5. 선착순 확정	시스템	가장 먼저 수락한 1명을 매칭 확정(status=matched), 나머지 지목 건은 마감

9.2 선착순 확정 규칙

- 지목된 케어자 중 최초 수락(신청) 1명을 매칭 확정한다 — 수락 시각(accepted_at) 오름차순 1위.
- 1명이 확정되면 동일 요청의 나머지 지목 케어자 건은 자동 마감되어 더 이상 수락할 수 없다.
- 확정은 원자적으로 1건만 성립한다 — 동시 수락 경합 시 DB 레벨에서 선착 1명만 성공하고 나머지는 「이미 마감」 응답을 받는다.
- 지목 케어자 전원이 미수락·거절하거나 응답 기한이 지나면 요청은 만료(expired) 처리된다.

9.3 자동 매칭과의 차이

구분	자동 매칭	보호자 수동 매칭
후보 선정	AI 점수화·정렬(3~5장)	보호자가 직접 다중 선택
후보 수	상위 top_k	보호자가 고른 N명
성사 기준	보호자가 1명 선택 → 인력 수락	지목 케어자 중 선착순 수락
매칭 결정권	보호자(후보 선택)	케어자(수락 순서)
점수 활용	ai_score 0~1로 정렬	점수 무관(선착순)

9.4 상태 흐름

수동 매칭 요청도 자동 매칭과 동일한 상태값(8장)을 사용하며, open에서 곧바로 matched로 전이한다.

- open — 수동 매칭 요청 생성, 지목 케어자에게 통보·수락 대기.
- matched — 최초 수락자 1명 확정(이후 케어세션·계약 진행).
- expired — 지목 케어자 전원 미수락/거절 또는 응답 기한 만료.

matching(후보 선택 후 인력 응답 대기)은 자동 매칭 전용 단계로 수동 매칭에는 해당하지 않는다.

10. 학습기반 매칭 (L2R) — 룰 위의 학습 레이어

rule-v3의 가중치(특기 0.4·거리 0.3·평점 0.2·경험 0.1 등)는 사람이 정한 휴리스틱이다. L2R(Learning-to-Rank)은 동일한 신호 위에 과거 '추천 후보 → 보호자 실제 선택' 이력을 정답으로 삼아 최적 가중치를 데이터로 학습한다. 핵심 원칙은 '데이터가 충분할 때만 학습 모델을 쓰고, 부족하면 자동으로 rule-v3로 폴백'하여 정성껏 튜닝한 룰을 과적합 모델로 훼손하지 않는 것이다.

10.1 학습 데이터·라벨

match_candidates 1행 = 1 학습 샘플. 라벨 = 그 후보의 돌봄전문가가 해당 요청의 실제 매칭(matches)으로 선택됐는가(1/0). feature는 서빙과 동일한 함수(l2r.subscores)로 계산하여 학습-서빙 feature 불일치(skew)를 원천 차단한다.

10.2 모델·블렌딩

로지스틱 회귀로 P(선택)을 산출하고, 최종 점수 = $(1 - w) \cdot \text{rule_score} + w \cdot P(\text{선택})$ 로 재랭킹한다(w = 블렌딩 가중, 기본 0.5). 성별 정렬 파티션·하드 필터·임계(min_score) 우회 등 안전 정책은 rule-v3와 동일하게 점수 산출 바깥에서 그대로 적용된다.

10.3 데이터 임계 게이트 (안전장치)

학습 표본 수와 양성(선택) 표본 수가 임계 미달이거나 모델이 없으면 모델을 비활성화하고 순수 rule-v3로 동작한다. 표본이 임계를 넘으면 주간 재학습이 코드 변경 없이 L2R을 자동 활성화한다. 환경변수로 강제 on/off도 가능하다.

10.4 게이트 파라미터

파라미터	기본값	의미
ML_L2R_MIN_SAMPLES	200	L2R 활성 최소 학습 표본 수
ML_L2R_MIN_POSITIVE_SAMPLES	60	L2R 활성 최소 양성(선택) 표본 수
ML_L2R_ALPHA	0.5	블렌딩 가중(모델:룰 비중)
ML_L2R_ENABLED	(자동)	1=강제 활성 / 0=강제 비활성 / 미설정=임계 자동 판정

10.5 운영·재학습

학습기 train_l2r.py가 DB 이력으로 재학습하며 교차검증 AUC를 산출하고 아티팩트(models/l2r/)를 저장한다. retrain.sh가 매주 일요일 04:10(KST) 재학습 후 AI 서비스를 재시작해 새 모델과 게이트 판정을 반영한다. 상태는 GET /ai/match/l2r-status 와 /health 의 matching 태그로 점검한다.

현황(2026-06-28): 학습 표본 71·양성 17·교차검증 AUC 0.557(무작위 0.5 수준) → 게이트 OFF, 라이브는 rule-v3 유지. 파이프라인·재학습 자동화는 완성되어 데이터가 임계를 넘으면 자동 고도화된다.

11. 한계 및 향후 과제

- 학습형 매칭은 경량 L2R(로지스틱 회귀, 10장)로 도입 — 다만 현재 학습 데이터 부족으로 게이트 OFF 상태(라이브는 rule-v3 동작), 데이터 축적 시 자동 활성. ALS·임베딩(KoSimCSE)은 데이터·의존성 제약으로 보류.
- 가용성(스케줄) 충돌 신호는 스케줄 데이터 불완전으로 미반영.
- 거리 신호는 좌표가 채워져야 변별력 발생(미상 시 0.5 중립).



Care& AI 이상징후 탐지 설계 문서

어르신 활력·생활 지표 기반 위험징후 조기 탐지 (anomaly rule-v1)

작성일: 2026-06-27 · 대상: caren.aiclaude.kr AI 서비스(FastAPI)

1. 개요

케어 세션에서 수집된 어르신의 식사·수면·정서·활력징후(혈압·심박·체온)를 규칙 기반으로 평가하여 영양·우울·섬망·낙상 4개 위험 유형의 점수를 산출하고, 가장 높은 위험을 대표 알림으로 제시한다. 현재 rule-v1(고정 임계 규칙)로 구현되어 설명 가능성이 높고 데이터 의존도가 낮다.

2. 입력 피쳐 (AnomalyFeatures)

피쳐	의미	비고
window_days	집계 기간(일)	기본 7
meal_pct_avg	평균 식사량(%)	0~100
meal_pct_3day_min	최근 3일 평균 식사량(%)	급감 감지
sleep_hours_avg	평균 수면시간(h)	
mood_score_avg	평균 정서점수	0~100
bp_sys_max / bp_sys_min	수축기 혈압 최고/최저	
heart_rate_max / min	심박수 최고/최저	
body_temp_max	최고 체온(°C)	

3. 위험 유형별 판정 규칙

위험 유형	트리거 규칙	점수 산식(최대 100)
영양(nutrition)	평균 식사 <70% 또는 최근3일 <50%	(70평균)×1.5 / 50+(503일)
우울(depression)	평균 정서점수 <60	(60정서)×1.5
섬망(delirium)	수면 <5h, 심박 변동 >40bpm, 체온 ≥38°C	(5수면)×15 + (변동40) + 30(발열)
낙상(fall)	수축기 변동 >30mmHg 또는 최고 >160	(변동30)×2 + 20(고혈압)

4. 점수·심각도 산정

각 위험 유형 점수는 0~100으로 클램프한다. 발생한 위험 중 최고 점수를 대표 위험(risk_type)으로 선택하고, 점수에 따라 심각도(severity)를 매긴다.

심각도	점수 구간
critical	80 이상
high	60~79
mid	40~59
low	40 미만(또는 위험 없음)

5. 응답 및 권고

필드	설명
risk_score	대표 위험 점수(0~100)
risk_type	대표 위험 유형(nutrition/depression/delirium/fall/none)

필드	설명
severity	심각도(critical/high/mid/low)
trigger_pattern	발동 근거 목록(예: 평균 식사량 55%)
recommendation	유형별 권고 조치 목록
all_risks	발생한 전체 위험 목록

권고 예: 영양→수분/영양 보충식·영양 상담, 우울→가족 방문·정서 활동·정신과 상담, 섬망→수면환경 점검·즉시 의료 상담·탈수·약물 점검, 낙상→혈압약 확인·환경 안전점검·보행 보조.

6. API 및 백엔드 연동

POST /ai/anomaly/score · 인증: Bearer 토큰(AI_SERVICE_TOKEN)

백엔드는 어르신의 최근 활력·생활 기록을 집계해 AnomalyFeatures 를 구성하고 스코어를 요청한다(POST /seniors/{id}/anomaly-alerts/scan). 반환된 위험은 알림으로 저장되어 관리자 모니터링·보호자 통지의 근거가 된다.

7. 한계 및 향후 과제

- 고정 임계 규칙 기반 — 개인별 기준선(baseline) 미반영. 평소 소식하는 어르신은 오탐 가능.
- 지표 간 상호작용·추세(점진적 악화)는 부분 반영. 시계열 추세·개인화 모델은 향후 과제.
- 입력 데이터(식사·활력) 기록 충실도에 정확도가 좌우됨.



Care& AI 수요예측 설계 문서

지역 매칭 수요·인력 수급 예측 (seasonal-naive-v1, DB 이력 기반)

작성일: 2026-06-27 · 대상: caren.aiclaude.kr AI 서비스(FastAPI)

1. 개요

향후 일자별 매칭 요청 수요를 예측하여 인력 수급·배치 계획에 활용한다. 최근 매칭 요청 이력의 요일별 계절성(seasonal naive)을 이용하며, 동시에 현재 활성 인력 수를 함께 제공해 수요·공급을 한 화면에서 비교할 수 있게 한다.

2. 알고리즘 (seasonal-naive-v1)

- 최근 56일(lookback)의 일별 매칭요청 건수를 집계한다. 요청이 없던 날은 0건으로 채워 연속 시계열로 만든다.
- 요일(월~일)별 평균 건수를 계산한다(요일 계절성). 표본이 없는 요일은 전체 일평균으로 보간한다.
- 향후 N일(최대 30일) 각 날짜의 요일 평균을 예측값으로 사용한다.
- 활성 인력 수(available_caregivers)는 status=active·미삭제 기준 실측값을 함께 반환한다.

3. 입력 / 출력

구분	필드	설명
입력	region	지역 라벨(기본 '서울')
입력	days	예측 일수(1~30, 기본 7)
출력	forecasts[]	날짜별 {date, predicted_requests, available_caregivers}
출력	history_days	사용한 이력 기간(56일)
출력	history_total_requests	이력 구간 총 요청 수
출력	model	seasonal-naive-v1

4. API 및 백엔드 연동

POST /ai/forecast/demand · 인증: Bearer 토큰(AI_SERVICE_TOKEN)

DB(match_requests, caregivers)에 직접 접속해 집계한다. 관리자 대시보드의 수요·수급 위젯에서 호출하여 향후 수요 곡선과 가용 인력을 함께 표시한다.

5. 한계 및 향후 과제

- 요일 계절성만 반영 — 장기 추세(증가/감소), 공휴일·연휴·캠페인 이벤트 효과는 미반영.
- region 파라미터는 현재 라벨 수준(집계는 전역). 지역별 분리 집계는 데이터·주소 정합 후 확장 가능.
- 56일 단기 윈도우 기반 — 계절(분기) 단위 패턴 학습은 장기 이력·시계열 모델(Prophet/ETS) 도입 시 개선.



Care& AI 챗봇 설계 문서

상담 챗봇 + 산후조리 챗봇 (Gemini LLM + 폴백)

작성일: 2026-06-27 · 대상: caren.aiclaude.kr AI 서비스(FastAPI)

1. 개요

Care& 챗봇은 (1) 장기요양·돌봄 일반 상담 챗봇과 (2) 산후조리 전문 챗봇 두 가지를 제공한다. 둘 다 Gemini(LLM) API로 답변을 생성하되, API 키 미설정·호출 실패 시 안전한 폴백(지식베이스 안내문/규칙 기반 답변)으로 대체하여 항상 응답한다.

2. LLM 연동

항목	값
API	Gemini API (generativelanguage.googleapis.com)
모델	GEMINI_MODEL (기본 gemini-2.5-flash)
호출	system + user 메시지, 타임아웃 40초
폴백 조건	키 없음 / HTTP 오류 / 빈 응답 → None 반환 → 호출부 폴백
현재 상태	LLM_PROVIDER=gemini · 운영 중

3. 일반 상담 챗봇

POST /ai/chatbot/answer

장기요양보험·재가급여·요양보호사 매칭·시니어 돌봄 전반을 한국 기준으로 3~5문장 존댓말로 답한다. 수치·제도는 확실할 때만 제시하고 불확실하면 공단(1577-1000)·기관 확인을 권한다. 의료 판단이 필요한 질문은 의료진 상담을 권한다. 질문 키워드로 관련 지식베이스 출처(sources)를 함께 반환한다.

폴백: 점검 안내문 + 공단/고객센터 연결 안내(model=kb-fallback).

4. 산후조리 챗봇

POST /chatbot/postpartum

산모 회복·모유수유·신생아 돌봄을 산모 컨텍스트(출산 경과일·초산 여부·수유 방식)와 최근 대화 6턴을 반영해 4~6문장으로 답한다. 발열·출혈·통증 악화 등 위험 신호 언급 시 의료진 진료를 최우선 권고한다.

폴백: 경과일·초산·수유 여부에 따른 규칙 기반 안내(model=rule-fallback).

5. 지식베이스(KB) 출처

주제 키워드	출처	내용
등급·한도·재가급여	장기요양보험 (longtermcare.or.kr)	등급별 한도·본인부담 안내
요양보호사·자격·방문요양	보건복지부 (mohw.go.kr)	요양보호사 자격·서비스 안내
치매·인지·섬망	중앙치매센터 (nid.or.kr)	치매 단계별 돌봄 가이드

6. 안전 정책

- 의료적 판단이 필요한 질문은 반드시 의료진/의료기관 상담을 권고한다.
- 불확실한 수치·의학 정보는 단정하지 않고 공식 기관 확인을 안내한다.
- 위험 신호(발열·출혈 등) 언급 시 즉시 진료 권고를 최우선으로 한다.

7. 한계 및 향후 과제

- 현재 LLM_PROVIDER=gemini로 Gemini 답변 활성(운영). 키 미설정·호출 실패 시 안전 폴백.
- KB는 키워드 매칭 기반(RAG 아님). 문서 임베딩 검색 도입 시 출처 정확도·범위 향상.
- 대화 메모리는 최근 6턴 윈도우 — 장기 맥락 유지는 세션 요약 기법 도입 검토.



Care& AI STT 시스템 설계 문서

음성 케어일지 전사(Speech-to-Text) — 엔진·파이프라인·API·운영

작성일: 2026-06-27 · 대상: caren.aiclaude.kr AI 서비스(FastAPI) + 백엔드(Laravel) · 엔진: faster-whisper (CPU int8)

1. 개요

Care& 는 요양보호사가 케어 세션 중 남긴 음성 기록을 텍스트로 전사(STT)하고, 이를 LLM/휴리스틱으로 요약하여 보호자·의료진용 케어일지를 생성한다. STT는 AI 서비스(FastAPI) 안에서 faster-whisper (CPU, int8 양자화)로 실구현되어 있으며, 음성 업로드부터 일지 저장까지 비동기 큐로 처리한다.

핵심 설계 원칙: 인식 실패 시 가짜 텍스트를 절대 반환하지 않는다. 모델 부재·엔진 오류는 5xx로 응답하고 호출측이 실패로 처리하여, 잘못 인식된 일지가 보호자에게 노출되는 것을 막는다.

2. 처리 파이프라인

음성 업로드 → 큐 적재 → STT 전사 → LLM 요약 → 케어일지 저장 → (보호자 알림)

요양보호사가 세션에 음성을 업로드하면 VoiceLog 가 생성되고 ProcessVoiceLogJob 이 큐(Redis)에 적재된다. 워커가 STT→요약을 순차 수행하며 각 단계마다 VoiceLog 상태를 갱신한다. CPU 전사가 수 초 블로킹되므로 동기 처리하지 않고 큐로 이관했다.

단계	주체/엔드포인트	내용
1. 업로드	POST /care-sessions/{id}/voice-log	음성 저장 → VoiceLog 생성 → ProcessVoiceLogJob dispatch
2. 전사(STT)	AI: POST /ai/voice/transcribe	faster-whisper 전사 → stt_text:confidence (status=transcribed)
3. 요약	AI: POST /ai/voice/summarize	어르신 컨텍스트로 보호자/의료 요약 생성(LLM, 키 없으면 휴리스틱 폴백)
4. 저장	백엔드(AiLogSummary)	요약·분류 저장(status=summarized). 실패 시 status=failed·error_message

3. STT 엔진 사양

항목	값	비고
엔진	faster-whisper (CTranslate2)	OpenAI Whisper의 CT2 최적화 구현
디바이스 / 양자화	CPU / int8	GPU 없음. 메모리·속도 절충
모델	small-ct2 (현재) / base-ct2	WHISPER_MODEL 로 교체. small 464MB, base 142MB
스레드	cpu_threads = 2 (WHISPER_THREADS)	2코어 박스
로딩	lazy 로드(첫 호출 시) 후 상주	프로세스 메모리에 유지
동시성	추론 락으로 직렬화(_whisper_infer_lock)	2코어에서 동시 추론 방지
VAD	vad_filter = True	무음 구간 제거로 정확도·속도 개선
언어	기본 ko (요청 language)	info.language 로 감지 결과 반환

박스 가용 RAM이 빠듯하여(~1.7G) 기본 모델은 base. 정확도 향상을 위해 운영은 small 로
상향함(WHISPER_MODEL=/root/careand-ai-service/models/small-ct2). 그 이상(medium 등)은 RAM 주의.

4. STT API 명세

POST /ai/voice/transcribe · 인증: Bearer 토큰(AI_SERVICE_TOKEN)

요청

필드	타입	설명
audio_url	string	음성 파일 URL(http/https) 또는 서버 로컬 경로
language	string	전사 언어. 기본 ko

응답

필드	설명
stt_text	전사 텍스트(세그먼트 결합)
confidence	신뢰도 0~1 (avg_logprob 기반)
duration_sec	오디오 길이(초)
language	감지된 언어
model	사용 모델 라벨 (예: faster-whisper-small-ct2-int8)

5. 오디오 입력 처리

audio_url 이 http/https면 다운로드(최대 50MB, 30초 타임아웃) 후 임시파일로 전사하고 종료 시 삭제한다. 로컬 경로면 그대로 사용한다.

상황	HTTP	처리
정상	200	전사 결과 반환
50MB 초과	413	파일 과대(>50MB) 거부
빈 파일	422	empty audio file
URL 접근 불가	422	audio_url not reachable
모델 미준비	503	fetch_model.sh 로 모델 준비 필요
엔진 오류	502	STT engine error (가짜 텍스트 미반환)

6. 신뢰도(confidence) 산출

$\text{confidence} = \text{clamp}(\exp(\text{평균 avg_logprob}), 0, 1)$, 세그먼트 없으면 0.0

각 세그먼트의 평균 로그확률을 지수화하여 0~1로 환산한다. 값이 낮으면 잡음·발화 불명확 가능성이 높아 후속 요약·검수 시 참고 지표로 쓰인다.

7. 실패 처리 정책 (가짜 텍스트 금지)

- 모델 파일이 없으면 503 — 절대 임의/가짜 텍스트를 만들지 않는다(런타임 네트워크 다운로드도 안 함).
- 전사 엔진 예외는 502로 응답하고 임시파일을 정리한다.
- 백엔드 job은 예외 시 VoiceLog.status=failed, error_message 기록 → 잘못된 일지가 보호자에게 노출되지 않는다(요약 단계로 진행하지 않음).

8. 모델 운영

- 모델 준비는 fetch_model.sh 전담(egress 플랩 대응 curl 재시도 다운로드). 서비스는 local_files_only=True 로 요청 시점에 절대 다운로드하지 않는다(행 방지).
- 모델은 models/ 하위에 디렉토리로 보관(base-ct2 142MB, small-ct2 464MB). WHISPER_MODEL 환경변수로 경로/이름 교체 후 서비스 재시작.
- 현재 운영 모델: small-ct2 (정확도 우선). 메모리 압박 시 base 로 하향 가능.

9. 백엔드 연동 및 상태 흐름

VoiceLog 상태: transcribing → transcribed → summarized (실패 시 failed). 호출 타임아웃은 전사 60초, 요약 30초이며 Job은 최대 3회 재시도(timeout 120초).

상태	의미
transcribing	STT 전사 진행 중
transcribed	전사 완료(stt_text·confidence 저장)
summarized	요약 생성·저장 완료(AiLogSummary)
failed	전사/요약 실패(error_message 기록)

10. 한계 및 향후 과제

- CPU·int8·small 모델 기준의 정확도/속도 한계. GPU·대형 모델은 현재 박스 RAM(~1.7G) 제약으로 미적용.
- 화자 분리(diarization)·실시간 스트리밍 미지원(파일 단위 일괄 전사).
- 요약 단계 LLM은 ANTHROPIC_API_KEY 미설정 시 휴리스틱 폴백으로 동작(전사 자체와는 무관).
- 도메인 특화 용어(약물명·질환명) 인식 향상을 위한 사후 교정 사전은 향후 과제.